

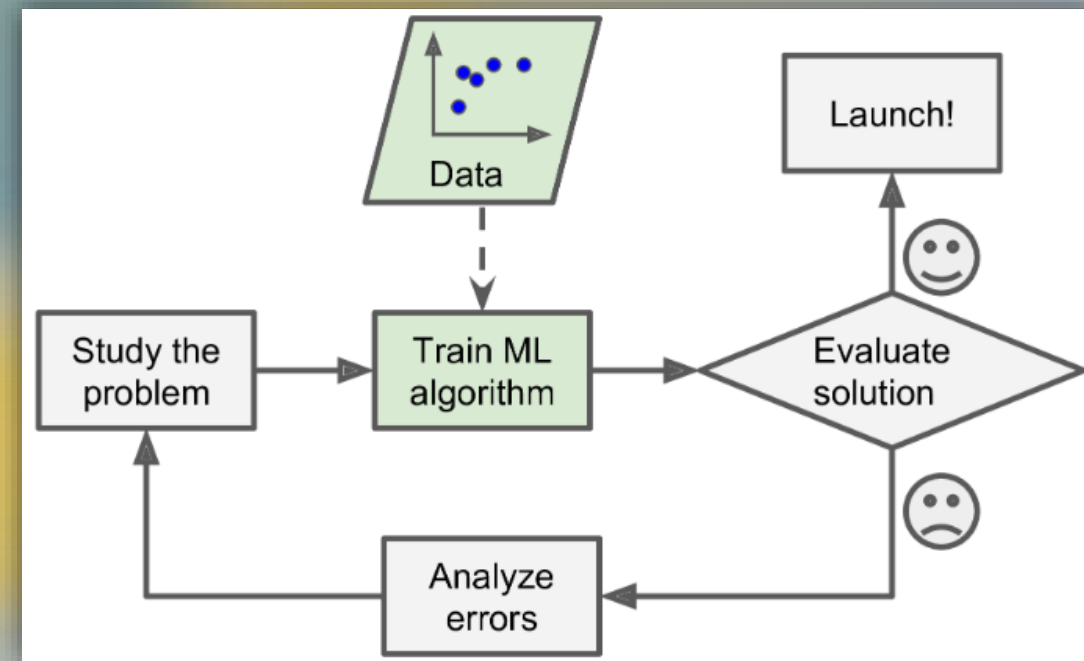
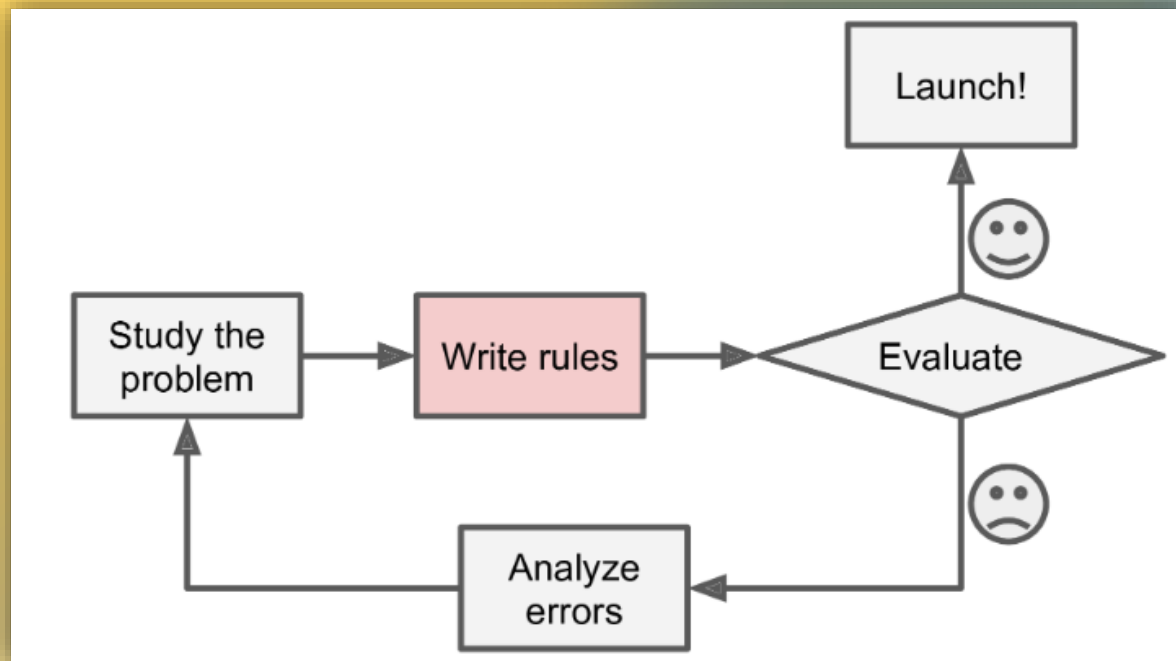
# 2. Előadás

## Osztályozás

### Logisztikus regresszió

### Softmax regresszió

# A determinisztikus és gépi tanulás szemlélet




🐍 Határozzuk meg az inputokat, outputokat, célokat és eszközöket a két irányzat szerint!

# Az adatok észszerűtlen hatékonysága

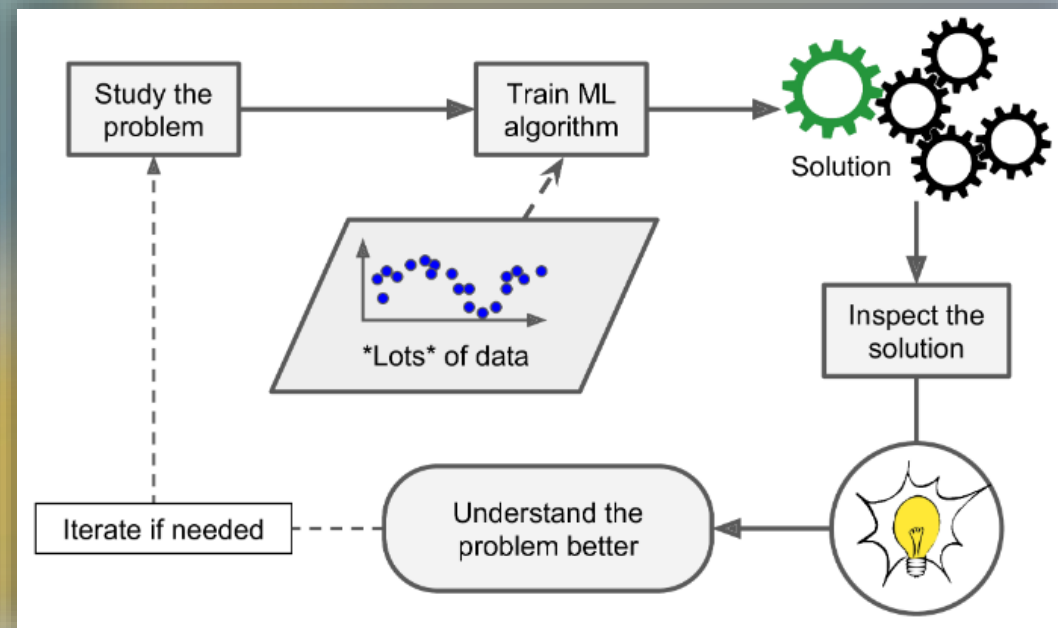
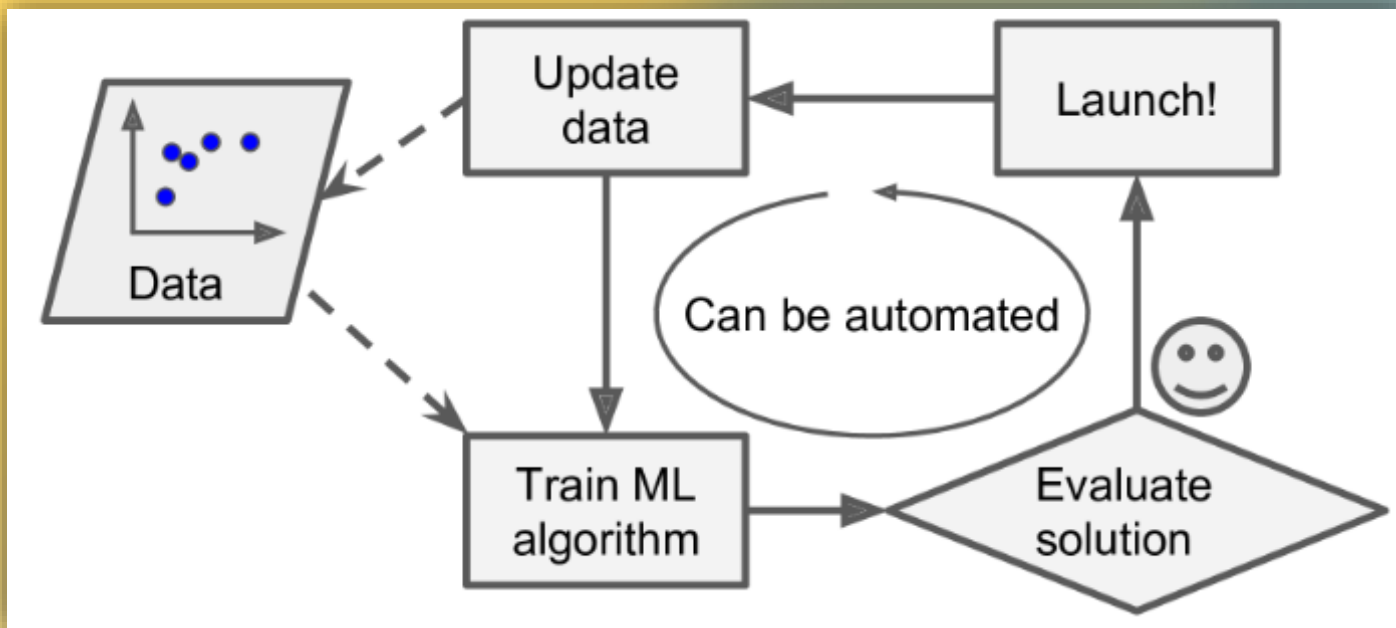
🐍 2001-es [kutatásukban](#) Michele Blanko és Eric Brill kimutatták, hogy a különböző ML algoritmusok (az egyszerűek is) hasonlóan jól teljesítenek a természetes nyelvfelismerés területén, ha elég sok adaton tanítják a modelleket.

🐍 Ahogy ők fogalmaztak: „Az eredmények azt mutatják, hogy újra kell gondolnunk, mire fordítjuk a pénzünket és erőforrásainkat: algoritmusok fejlesztésére, vagy adatgyűjtésre.”

🐍 Miért van olyan sok béna játék a facebookon?



# Tanítás automatizálása adat-alapúan



🐍 Hogyan taníthatja egymást ember és gép a gépi tanulás szemlélete szerint?





# Osztályozás

- 🐍 A felügyelt tanulás másik nagy irányzata a regresszió mellett.
- 🐍 Osztályozásról beszélünk, amikor a predikció célváltozója kettő- vagy több, egymással átfedésben nem álló **diszjunkt kategóriára** osztható.
- 🐍 Az osztályozás problémája esetén szeretnénk megismerni egy előre partícionált adathalmaz belső struktúráját. A partíciókat nevezzük kategóriának vagy osztálynak.
- 🐍 Tárgya egy **diszkrét** változó.




# Modellalapú tanítás

- 🐍 Az osztályozó modellt arra használjuk fel, hogy eddig még nem látott mintaegyedek címkeit (osztályait) megjósoljuk vele.
- 🐍 A modell inputja az osztályozási probléma esetén egy olyan adathalmaz, amely már fel van osztva partíciókra. Ez a **tanító adat/training data**.
- 🐍 A modell teljesítményét egy külön erre a célra elkülönített adathalmazzal mérjük: ez a **teszt adat/testing data**.



# Az osztályozás fajtái

- Bináris:** a modell két lehetséges osztály közül valamelyikbe sorolja be az egyedeket. Minden egyedhez legalább és legfeljebb 1 osztály tartozik.
- Multiclass:** több, mint két lehetséges kategória létezik, amibe az egyedek besorolhatók, ezek közül az egyikbe fog sorolódni az egyed. Minden egyedhez legalább és legfeljebb 1 osztály tartozik.
- Multilabel:** minden mintaegyedhez több bináris vagy multiclass címketekategóriából tartozik elem. Pl. [Szem: *zöld*, Haj: *hosszú*]
- Multiooutput:** A multilabel osztályozás generalizált változata. Egy egyedhez egy multilabel halmazból több elem is tartozhat. Pl: [Mail: [*spam*, *ad*, *junk*]]
- Mikor a legrosszabb egy osztályozó modell?





Példa: írott  
számjegyek képei  
alapján készítsünk  
prediktort, ami  
megadja, milyen szám.

🐍 Regresszió vagy osztályozás?

5	0	4	1	9	2	1	3	1	4
3	5	3	6	1	7	2	8	6	9
4	0	9	1	1	2	4	3	2	7
3	8	6	9	0	5	6	0	7	6
1	8	7	9	3	9	8	5	9	3
3	0	7	4	9	8	0	9	4	1
4	4	6	0	4	5	6	1	0	0
1	7	1	6	3	0	2	1	1	7
8	0	2	6	7	8	3	9	0	4
6	7	4	6	8	0	7	8	3	1



# A logisztikus regresszió

- 🐍 Statisztikai modellezési eljárás annak a **valószínűségnek** a megbecslésére, hogy egy adott mintaelem **valamely osztályba tartozik-e vagy sem** → **bináris osztályozás**.
- 🐍 Ha a becsült valószínűség magasabb, mint egy adott **küszöbérték** (leggyakrabban 50%), a modell úgy dönt, hogy beletartozik a pozitív osztályba (1-es osztály).
- 🐍 Ha a becsült valószínűség alacsonyabb mint 50%, a modell úgy dönt, hogy a negatív osztályba tartozik (0-s osztály).


$$\hat{y} = \begin{cases} 0 & \text{if } \hat{p} < 0.5 \\ 1 & \text{if } \hat{p} \geq 0.5 \end{cases}$$

# A logisztikus függvény

- 🐍 A logisztikus modellhez felírjuk  $z$ -t a már ismert lineáris módon, hogy legyen egy index ami összevonja az adatokat.
- 🐍 Majd behelyettesítjük a kapott lineáris kifejezést a logisztikus függvény jobb oldalába, hogy megkapjuk  $f(z)$ -t.

```
sig = 1 / (1 + np.exp(-t))
```

$$z = \underbrace{\alpha + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k}_{f(z)}$$
$$f(z) = \frac{1}{1 + e^{-z}}$$
$$= \frac{1}{1 + e^{-(\alpha + \sum \beta_i X_i)}}$$



# De miért bukik el a lineáris regresszió diszkrét kimenetek esetében?

🐍 Vegyünk egy példát! Jósoljuk meg, hogy a fehér fog-e nyerni egy sakkmeccsben az alapján, hogy a két versenyző rang pontszáma között mekkora a különbség. A következő tanító tábla alapján:

Fehér és Fekete játékos rangjának különbsége	Fehér nyert?
200	0
-200	1
300	0

🐍 Próbáljunk meg lineáris modellt felállítani az adatokra.  
Mit fogunk tapasztalni?



# A lineáris modell bukása

🐍 A lineáris modell a következő egyenletet eredményezi:

$$\text{fehér nyert} = 0.55 - 0.00214 * (\text{Rangok különbsége})$$

🐍 Ezzel a modellel a következő predikciókat kapjuk:

Fehér és Fekete játékos rangjának különbsége	Fehér nyert?	Lineáris predikció
200	0	0.11
-200	1	0.97
300	0	-0.1

🐍 Jól van ez így?

🐍 A modellünk minden esetben racionális megoldáshoz vezet?


# Hát nem!

🐍 Ahogy látható, a 300-as különbség olyan predikcióhoz vezetett, ami kevesebb, mint 0. Hasonlóan egy  $-300$ -as különbség is valótlan értéket adna becslésül.

🐍 Ebben az esetben a negatív értékek értelmetlenek. Negatív valószínűségek nem léteznek!

🐍 A predikcióra használt függvény szélsőértékei 0 a  $\infty$ -ben és 1 a  $-\infty$ -ben.

🐍 Az 1 feletti predikció 1 kell, hogy legyen, a 0 alatti pedig 0.



# Költséggüggvény egy mintaegyedre

- 🐍 A tanítás célja a  $\theta$  paraméter halmaz olyan beállításának megtalálása, hogy a modell magas valószínűséggel találjon meg pozitív egyedeket:  $\hat{y} = 1$
- 🐍 Emellett alacsony valószínűséggel találjon meg negatív egyedeket:  $\hat{y} = 0$
- 🐍 Tehát minél kevesebb legyen a bizonytalanság a modellben.
- 🐍 Ez az ötlet képeződik le az egy egyedre számított költséggüggvényben:

$$c(\theta) = \begin{cases} -\log(\hat{p}) & \text{if } y = 1 \\ -\log(1 - \hat{p}) & \text{if } y = 0 \end{cases}$$

- 🐍 A  $-\log(\hat{p})$  egyre magasabb, ahogy  $\hat{p}$  közelít a 0-hoz, tehát a költség magas lesz, amikor a modell pozitív osztályt nagy bizonyossággal jósol negatív egyedre.
- 🐍 Akkor is magas lesz, amikor nagy bizonyossággal jósol negatív osztályt pozitív egyedre.



# Költséggüggvény az összes mintaegyedre

🐍 A teljes tanító adathalmazra kiszámított költséggüggvény ( $J(\theta)$ ) egyszerűen az egyes tanító mintaelemekre kiszámított logisztikus költségek átlaga. Egyetlen kifejezésben felírható, ez a **log loss függvény**:

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m \left[ y^{(i)} \log(\hat{p}^{(i)}) + (1 - y^{(i)}) \log(1 - \hat{p}^{(i)}) \right]$$

🐍 A rossz hír: nincs olyan zárt formájú számítás, ami  $\theta$  azon halmazát adja, ami minimalizálja a költséggüggvényt.

🐍 A jó hír: a függvény **konvex**, ezért a minimum hely közelítése lehetséges ilyen eljárásokkal, pl. gradiens ereszkedéssel.

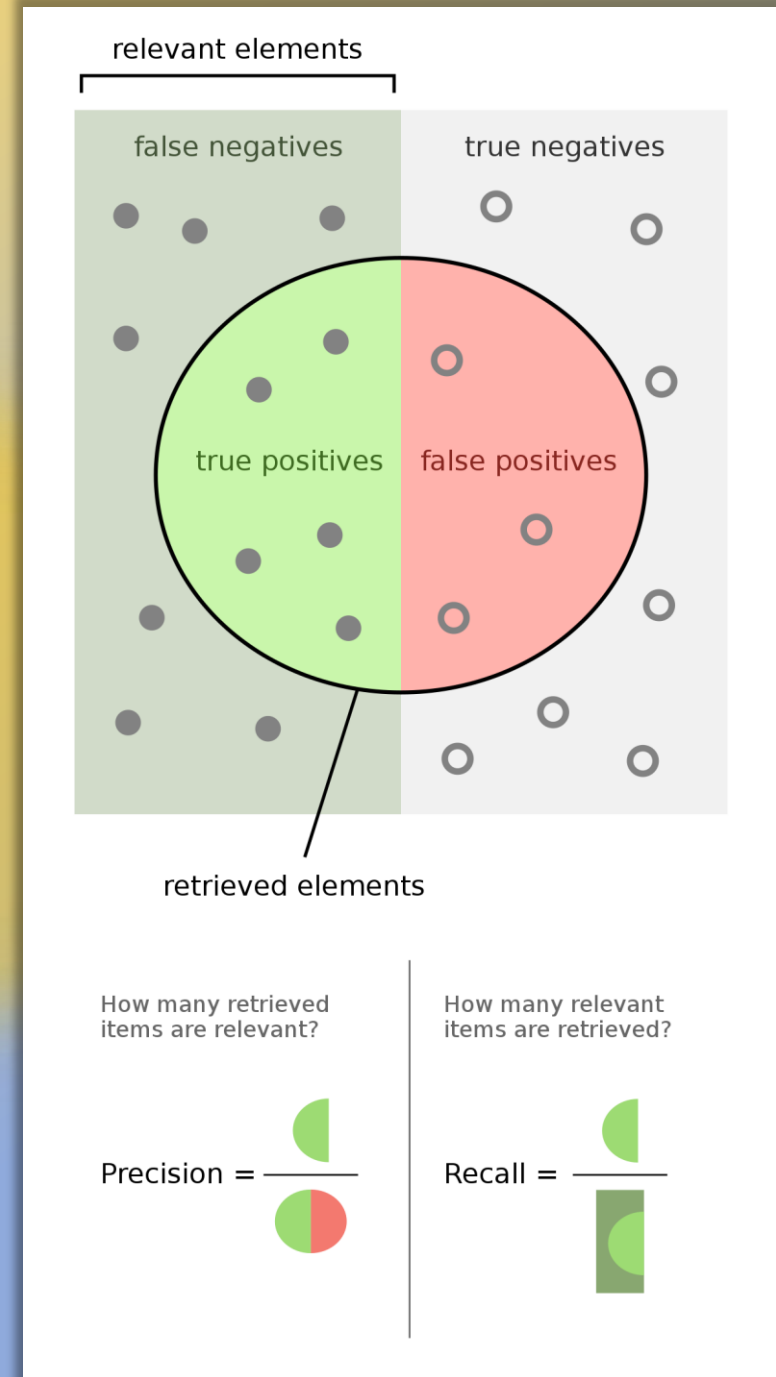
🐍 A költséggüggvénynek deriválhatónak kell lennie. Miért?

# Az osztályozás jóságának mérése

- 🐍 True Positive: pozitív egyed, és annak is van osztályozva. (**TP**)
- 🐍 True Negative: negatív egyed, és annak is van osztályozva. (**TN**)
- 🐍 False Positive: negatív egyed, de pozitívnak van osztályozva. (**FP**)
- 🐍 False Negative: pozitív egyed, de negatívnak osztályozva. (**FN**)
- 🐍 Két fontos mutató: **precision** és **recall**.

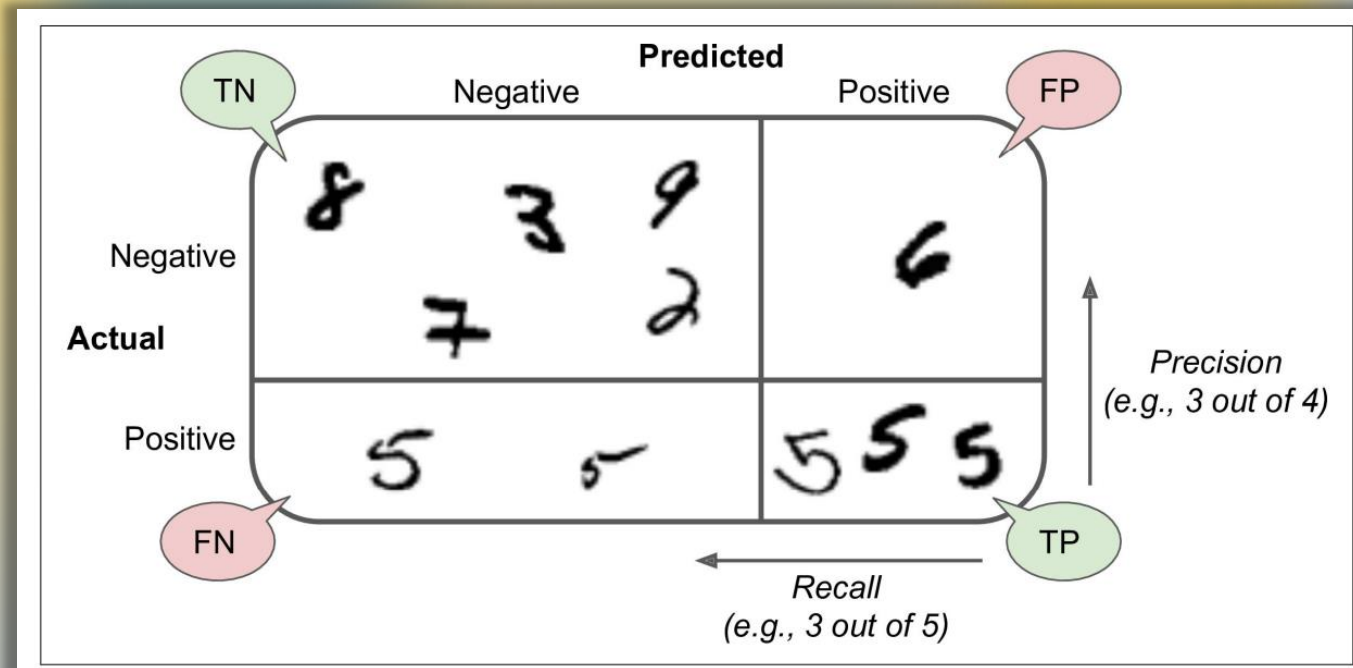
$$\text{precision} = \frac{TP}{TP + FP}$$

$$\text{recall} = \frac{TP}{TP + FN}$$



# A konfúziós mátrix



- 🐍 Az osztályozás jóságának mérőeszköze, a valós és becsült osztályokat hasonlítja össze minden mintaegyedre.
- 🐍 Minden sora egy valós érték, minden oszlopa pedig a becsült érték.
- 🐍 Annál jobb, minél több elem található a főátlón. (Nem csak 2x2!)






# Precision / Recall Tradeoff

- ☛ Sajnos nem lehet mindkettőre optimalizálni osztályozás esetén.
- ☛ Vagy a precision szerint teljesít jól a modell, vagy a recall szerint.
- ☛ A döntési küszöb értékéből következik, hogy melyiket részesíti előnyben a modell.




# A logisztikus modell

🐍 Használjuk fel a logisztikus regressziót arra, hogy a szíromszélesség alapján megjósoljuk, hogy egy virág az Iris Virginica osztályba tartozik-e!



# A modellünk egy 1-Dimenziós döntési határ

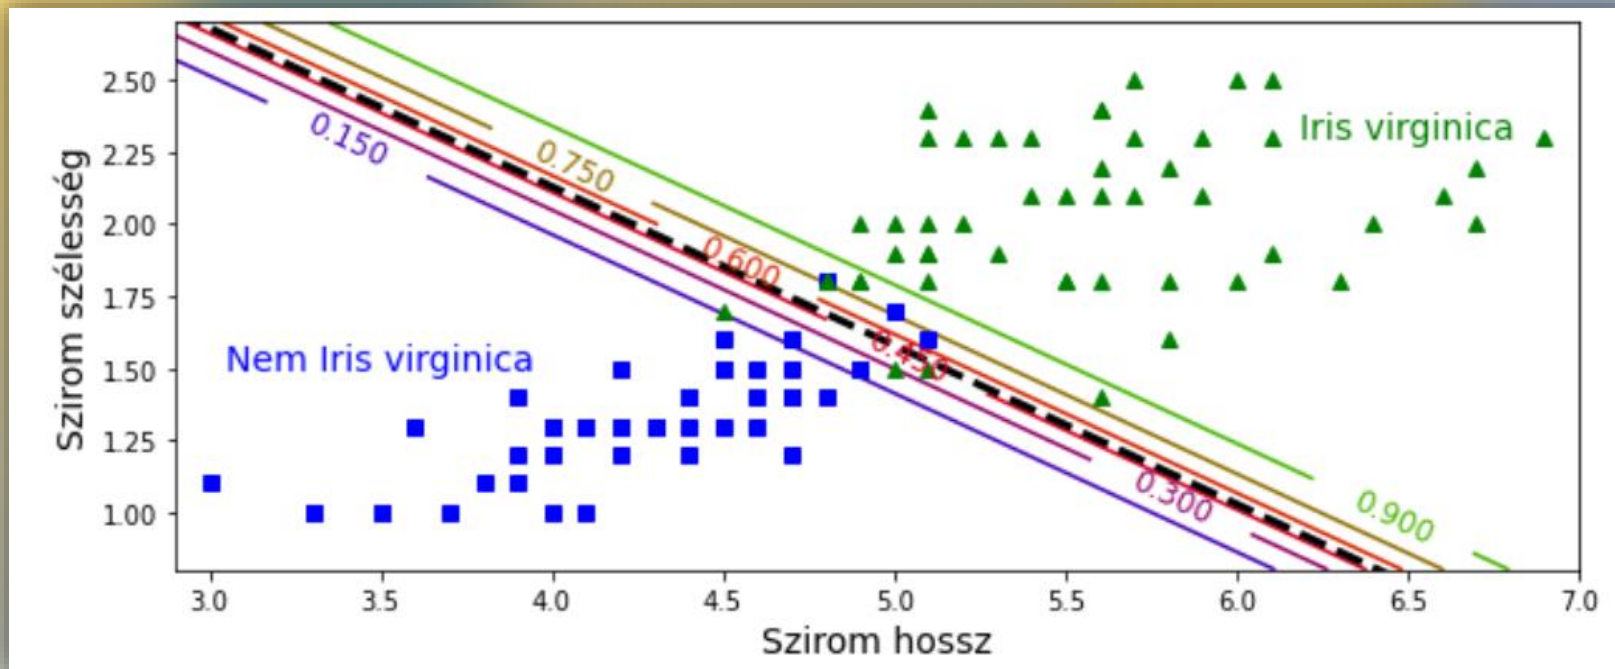
- 🐍 Az Iris Virginica szíromszélességei 1.4-től 2.5cm-ig terjednek, míg a többi Iris virág szirmai 0.1 és 1.8cm közöttiek.
- 🐍 Vegyük észre, hogy van egy pár elemnyi átfedés a két csoport között.
- 🐍 2cm fölött a modell egészen biztos benne, hogy Virginicáról van szó, 1cm alatt szinte biztos benne, hogy nem tartozik az osztályba. A két érték között viszont bizonytalan.





## 2-Dimenziós döntési határok

- 🐍 Egy változó (sziromszélesség) alapján 1-D döntési határt kapunk.
- 🐍 Ha bevesszük a modellbe a sziromhossz változót is, a logisztikus regresszió segítségével létrehozható egy 2-D döntési határ.
- 🐍 A határ felett a pozitív osztály, alatta a negatív osztály található.
- 🐍 Érdeemes megfigyelni, hogy még mindig vannak átfedések.



# Softmax regresszió

🐍 A logisztikus regresszió általánosítható olyan módon, hogy több osztályt is képes legyen közvetlenül megjósolni.

Ez a **softmax**, vagy multinomiális logisztikus regresszió.

🐍 Az algoritmus: ha van egy  $x$  egyed, a softmax modell kiszámítja  $s_k(x)$ -et minden  $k$  osztályra, az osztály  $\theta$  paraméter vektorának segítségével.

🐍 Egy  $k$  osztály softmax értéke:  $s_k(\mathbf{x}) = \mathbf{x}^T \boldsymbol{\theta}^{(k)}$

🐍 Majd minden osztályra kiszámítja a beletartozás valószínűségét ( $\hat{p}$ ), a softmax (normalizált exponenciális) függvény segítségével azáltal, hogy  $s_k$ -t behelyettesíti a softmax függvénybe:

$$\hat{p}_k = \sigma(\mathbf{s}(\mathbf{x}))_k = \frac{\exp(s_k(\mathbf{x}))}{\sum_{j=1}^K \exp(s_j(\mathbf{x}))}$$

# Softmax predikciók

🐍 Miután minden osztályra kiszámolta a softmax modell, hogy egy adott  $x$  mintaegyed mekkora valószínűséggel tartozik  $k$  osztályba, az algoritmus kiválasztja azt az osztályt, amihez a legnagyobb valószínűség tartozik:

$$\hat{y} = \operatorname{argmax}_k \sigma(\mathbf{s}(\mathbf{x}))_k = \operatorname{argmax}_k s_k(\mathbf{x}) = \operatorname{argmax}_k \left( \left( \boldsymbol{\theta}^{(k)} \right)^T \mathbf{x} \right)$$

🐍 Az argmax operátor a változónak azt az értékét téríti vissza, amelyik maximalizál egy függvényt.

🐍 Ebben a példában  $k$ -nak azt az értékét, amelyikhez a legnagyobb becsült valószínűség tartozik:  $\sigma(s(x))_k$



# A softmax modell

- 🐍 A kép a létrejövő döntési határokat mutatja. Vegyük észre, hogy a három osztály között a döntési határok lineárisak.
- 🐍 Az ábrán a görbe vonalakkal látható a versicolor-hoz tartozó valószínűség.
- 🐍 Képes-e a modell 50% alatti valószínűséggel osztályozni?
- 🐍 Mekkora valószínűség tartozik a három határ találkozásához?

